Sisteme de Operare

Administrarea perifericelor de stocare

Cristian Vidrașcu

https://profs.info.uaic.ro/~vidrascu

Cuprins

- > Introducere
- Memoria secundară (discul magnetic)
 - Structura
 - Planificarea
 - Administrarea
- Gestiunea spațiului de swap
- > Construirea unui disc mai bun
- > Administrarea memoriei terțiare

Introducere

- Clasificarea perifericelor (d.p.d.v. funcțional)
 - Periferice de intrare/ieșire pentru schimbul de informații cu mediul extern
 (e.g. tastatură, ecran, imprimantă, cititor de cartele, ș.a.)
 - Periferice de stocare pentru păstrarea nevolatilă
 (i.e. permanentă) a informațiilor
 (e.g. disc magnetic, bandă magnetică, dischetă, CD/DVD, ș.a.)

Alte clasificări ale perifericelor /1

- Clasificarea perifericelor d.p.d.v. al modului de operare (de servire a cererilor)
 - Periferice dedicate pot servi un singur proces la un moment dat (modelul tipic: imprimanta)
 - Periferice partajabile pot servi mai multe procese simultan, în sensul concurenței aparente (modelul tipic: discul magnetic)

Alte clasificări ale perifericelor /2

• Clasificarea perifericelor d.p.d.v. al modului de transfer și de memorare a informației

- Periferice bloc

- memorează informațiile în *blocuri* de lungime fixă, fiecare cu adresa sa
- blocul este unitatea de transfer între periferic și memoria internă
- fiecare bloc poate fi citit sau scris independent de celelalte blocuri
- blocul conține informații propriu-zise și, în plus, mai conține informații de control de paritate, pentru verificarea corectitudinii informației memorate
- informațiile stocate pot fi (re)citite de oricâte ori este nevoie și, de asemenea, pot fi rescrise (modificate) dacă se dorește acest lucru
- e.g. disc magnetic, bandă magnetică, CD/DVD, memorii flash, ș.a.

- Periferice caracter

Alte clasificări ale perifericelor /3

- Clasificarea perifericelor d.p.d.v. al modului de transfer și de memorare a informației (cont.)
 - Periferice bloc
 - Periferice caracter
 - furnizează/acceptă un *flux* de octeți fără nici o structură de bloc
 - octeții din flux nu sunt adresabili
 - fiecare octet este disponibil ca și *caracter curent* numai până la apariția următorului octet
 - informațiile transmise sunt consumate (i.e., datele respective nu pot fi recitite mai târziu)
 - e.g. tastatură, mouse, ecran, imprimantă, difuzor, ș.a.

Periferice de stocare

- Clasificarea perifericelor de stocare după variația timpului de acces (t_{ij} = timpul de acces de la informația i la informația j)
 - Periferice cu acces secvențial timpul de acces t_{ij} are variații foarte mari (modelul tipic: banda magnetică)
 - Periferice cu acces complet direct timpul de acces tij=k, este constant (modelul tipic: memoriile bidimensionale obișnuite RAM)
 - Periferice cu acces direct timpul de acces t_{ij} are variații foarte mici (modelul tipic: discul magnetic)

Discul magnetic

- Memoria secundară: discul HDD (intern)
- Fehnologia folosită, **discul magnetic** (apărut în anii '50), a fost standardizată începând de prin anii '70 (vezi <u>istoricul HDD</u>).
 - Structura discului
 - Planificarea acceselor la disc
 - Administrarea discului
- Notă: în anii '90 a apărut o tehnologie mai nouă: **discul SSD**, ce se bazează pe diferite tipuri de *memorii flash* (NAND). Această tehnologie este încă în curs de standardizare, astfel că fiecare producător folosește propria implementare proprietară a tehnologiei NAND (vezi <u>istoricul SDD</u>).

Structura discului /1

• Discurile magnetice sunt adresate ca o matrice 1-dimensională (un vector) foarte mare de **blocuri logice**, unde blocul logic este cea mai mică unitate de informații ce se poate transfera (între disc și memorie)

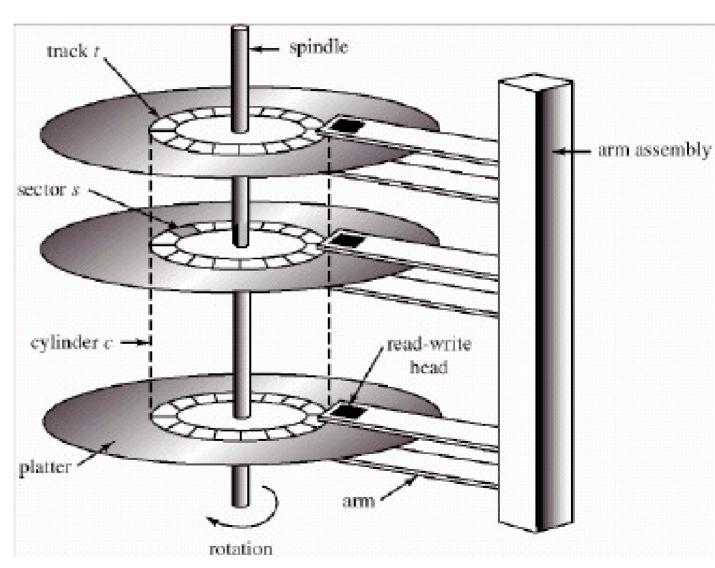
Indexul unui bloc în acest vector este adresa sa LBA.

• Matricea 1-dimensională de blocuri logice este *mapată* secvențial pe sectoarele discului

Adresa LBA se convertește în adresa fizică (C,H,S), de către BIOS (în trecut) sau firmware-ul discului (în prezent).

Structura discului /2

- Organizarea discului
 - platane
 - piste
 - cilindri
 - sectoare
 - data



Viteza discului

- Timpul de căutare (Seek time)
 - timpul necesar pentru mișcarea (mecanică a) ansamblului cu capetele de citire-scriere până la pista specificată
- Latența de rotație (rotational Latency)
 - timpul de așteptare necesar pentru ca începutul sectorului specificat să ajungă prin rotație sub capul de citire-scriere
- Timpul de transfer (Transfer time)
 - timpul necesar pentru a citi datele de pe sectorul specificat
- Timpul total de acces = S + L + T

Probleme

- Planificarea acceselor la disc
 - ideea este de a reorganiza cererile de acces la disc pentru a minimiza timpii de căutare (seek-urile)
- Plasarea datelor pe disc (Layout)
 - un mod de plasare care să minimizeze overhead-ul operațiilor cu discul
- Construirea unui disc mai bun (sau a unui substituent pentru discurile actuale)
 - exemplu: RAID

- Sistemul de operare este responsabil pentru utilizarea eficientă a hardware-ului
 - pentru discurile hard, aceasta înseamnă a avea
 un timp de acces rapid și o lățime de bandă mare
- Lățimea de bandă a discului (i.e., *disk bandwidth*) este numărul total de octeți transferați, împărțit la timpul total scurs între prima cerere de serviciu și sfârșitul ultimului transfer solicitat

- Timpul de acces are două componente majore:
 - seek time timpul necesar discului pentru a deplasa ansamblul cu capetele de citire-scriere la cilindrul ce conține sectorul dorit
 - rotational latency timpul adițional de așteptare pentru ca discul să rotească sectorul dorit sub capul de citire-scriere
 - cea de-a treia componentă, timpul efectiv de transfer, este o constantă specifică perifericului respectiv
- Planificarea discului urmărește minimizarea timpului de căutare, eventual și a latenței de rotație
- Ideea: schimbarea ordinii de servire a cererilor venite de la procesele concurente (cu păstrarea ordinii cererilor fiecărui proces)

- Algoritmi de planificare (a acceselor la disc)
 - FCFS (First Come, First Served)
 - SSTF (Shortest Seek Time First)
 - SCAN
 - C-SCAN (Circular SCAN)
 - LOOK
 - C-LOOK (Circular LOOK)

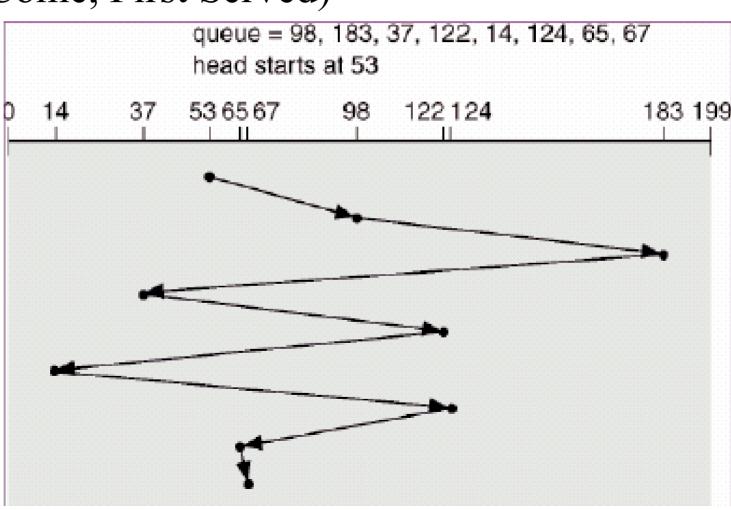
- Pentru exemplificările următoare ale algoritmilor de planificare, considerăm următorul scenariu:
 - un disc cu 200 cilindri (numerotați cu 0-199)
 - coada cererilor de acces (doar cilindrul ce conţine sectorul dorit): 98, 183, 37, 122, 14, 124, 65, 67 (fiecare cerere provenind de la un proces distinct)
 - poziția inițială a ansamblului cu capetele de citire-scriere a discului: cilindrul 53

• FCFS (First Come, First Served)

- Alg.: cererile sunt servite în ordinea sosirii
- Figura arată o
 mișcare totală a
 capului discului
 de 640 cilindri

Ipoteză de lucru:

"coada statică" (i.e., toate cererile au ajuns în coadă la momentul t=0, în ordinea specificată)



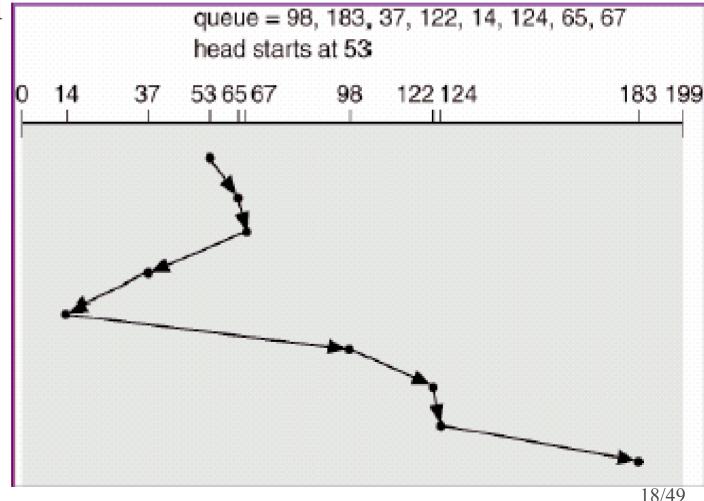
• SSTF (Shortest Seek Time First)

- Alg.: se alege cererea cu timp de căutare minim de la poziția

curentă a capului

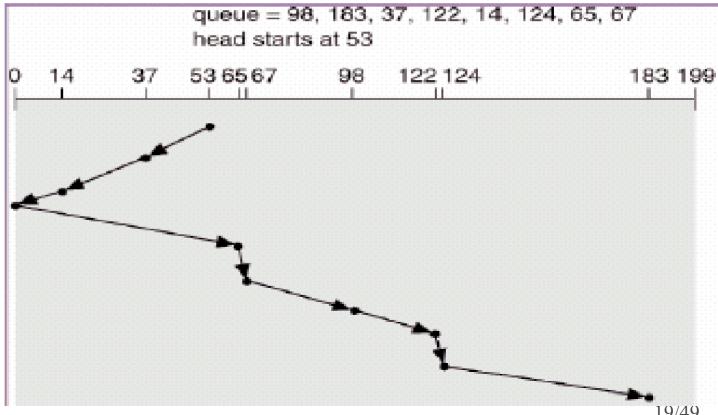
Figura arată o
 mișcare totală a
 capului discului
 de 236 cilindri

- Este mai eficient decât FCFS, dar nu este echitabil (poate favoriza fenomenul de *starvation*: întârzierea servirii unor cereri)



- SCAN (algoritmul elevator)
- Alg.: braţul cu capetele R/W începe la un capăt al discului şi se deplasează spre celălalt capăt, rezolvând şi cererile pe parcurs, iar când ajunge la celălalt capăt, se întoarce înapoi, continuând servirea cererilor
- Figura arată o mișcare totală a capului discului de 236 cilindri (în ipoteza că sensul inițial de deplasare era "în jos". Altfel, mișcarea totală este

de 331 cilindri).

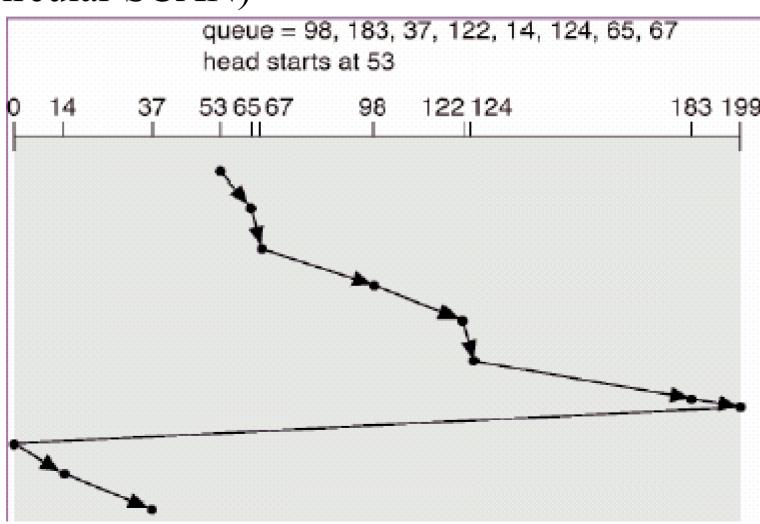


• C-SCAN (Circular SCAN)

- Alg.: braţul cu capetele R/W începe la capătul 0 al discului şi se deplasează spre celălalt capăt, rezolvând şi cererile pe parcurs, iar când ajunge la celălalt capăt, se întoarce "imediat" (*foarte rapid*) înapoi la începutul discului, fără să servească nici o cerere pe drumul de întoarcere, şi apoi reia lucrul
- Practic, acest algoritm tratează cilindrii discului ca o listă circulară care "conectează" ultimul cilindru cu primul cilindru
- Avantaj: furnizează un timp de așteptare (a rezolvării cererii)
 mai uniform decât algoritmul SCAN (la care este posibil ca o cerere să aștepte două parcurgeri ale discului până când este servită)

• C-SCAN (Circular SCAN)

- Exemplu:
- Figura arată o mișcare totală a ansamblului cu capetele R/W ale discului de 382 cilindri (în ipoteza că sensul inițial de deplasare era "în sus")

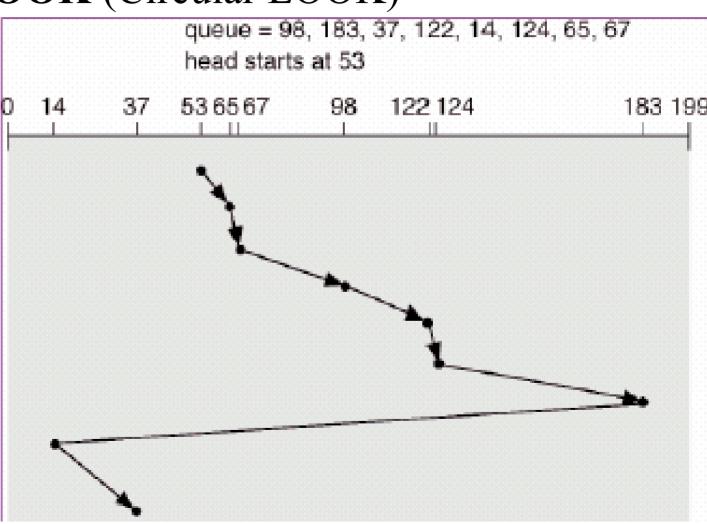


- LOOK și C-LOOK (Circular LOOK)
 - Alg.: braţul cu capetele R/W se mişcă la fel ca la algoritmii SCAN şi respectiv C-SCAN, cu deosebirea că aici se mişcă doar până la ultima cerere în fiecare sens, după care inversează direcţia de deplasare imediat, fără să meargă mai întâi până la capătul discului
 - Notă: practic, LOOK/C-LOOK reprezintă o optimizare a algoritmilor SCAN/C-SCAN

• LOOK și C-LOOK (Circular LOOK)

- Exemplu:
- Figura arată o
 mișcare totală a
 capului discului
 de 322 cilindri
 pentru C-LOOK
 (în ipoteza că sensul
 inițial de deplasare
 era "în sus")

Notă: aplicând alg. LOOK, deplasarea ar fi de 299 cilindri.



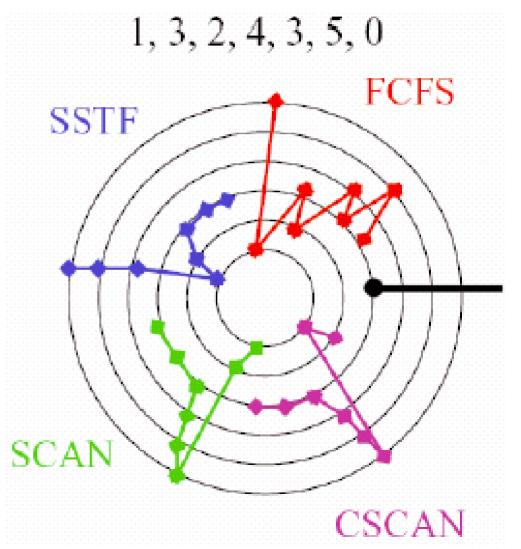
• Selectarea unui alg. de planificare a discului

- SSTF este utilizat frecvent (dezavantaj: pericol de înfometare a unor cereri de acces la disc)
- SCAN și C-SCAN se comportă mai bine pentru sisteme care au o *încărcare* mare a discului (i.e., multe operații I/O)
- Algoritmul de planificare a discului este indicat să fie scris ca un modul separat al sistemului de operare, pentru a permite o înlocuire ușoară a sa cu un alt algoritm dacă se consideră necesar
- Fie SSTF, fie LOOK este o alegere rezonabilă pentru algoritmul implicit de planificare a discului

• Observații

- Performanța depinde de numărul și tipurile cererilor de acces
- Cererile de acces pot fi influențate de metoda de alocare a fișierelor utilizată

Alt exemplu:



• Observații (cont.)

- De exemplu, la alg. SSTF cele mai favorizate d.p.d.v. al timpului de acces vor fi pistele din mijloc; ca urmare se pot aloca pe aceste piste fișierele cu frecvență ridicată de utilizare, sau structura de directoare (deoarece este folosită frecvent)
- La fel, la o recompactare (defragmentare) a discului,
 se pot aloca în aceste zone favorizate fișierele pentru
 care s-a constatat că au un grad de folosire mai ridicat

• Observații (cont.)

- în exemplele anterioare am simplicat expunerea, presupunând coada
 ca fiind statică (i.e., toate cererile ajungeau în coadă la momentul t=0)
- în realitate, coada este dinamică (i.e. **noi** cereri ajung în coadă pe parcursul trecerii timpului); iată un exemplu în acest sens:

Coada de cereri: 20, 45, 85 (toate ajung la t=0); 120, 97, 72 (toate la t=100 ms) Se dau: *seek time* = direct proporțional cu distanța (2 ms/traversarea a 2 cilindri consecutivi); *latența de rotație* = 1 ms (în medie, pentru toate cererile); *timpul de transfer* = neglijabil. Inițial, capul R/W este la cilindrul 50, iar sensul de deplasare este spre cilindrul cu nr. maxim.

Ordinea de servire a celor 6 cereri, folosind algoritmul LOOK, este:

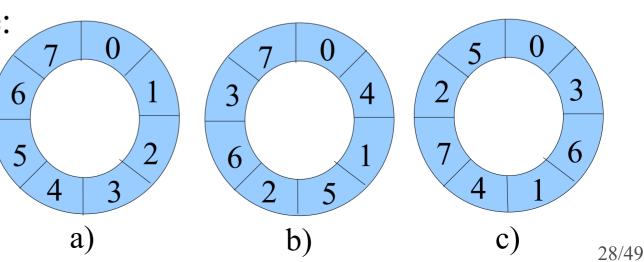
- 1) la momentul t=0, capul R/W este poziționat la cilindrul 50;
- 2) la momentul t=70ms, capul ajunge la cilindrul 85, iar după 1ms începe servirea cererii respective;
- 3) la momentul t=151ms, capul ajunge la cilindrul 45, iar după 1ms începe servirea cererii respective;
- 4) la momentul t=202ms, capul ajunge la cilindrul 20, iar după 1ms începe servirea cererii respective;
- 5) la momentul t=307ms, capul ajunge la cilindrul 72, iar după 1ms începe servirea cererii respective;
- 6) la momentul t=358ms, capul ajunge la cilindrul 97, iar după 1ms începe servirea cererii respective;
- 7) la momentul t=405ms, capul ajunge la cilindrul 120, iar după 1ms începe servirea cererii respective.

Reducerea așteptării rotației

- În SO-urile mai pretențioase se urmărește și minimizarea latenței de rotație
- Ideea: reordonarea servirilor cererilor existente la un moment dat pentru același cilindru – alg. SLTF (Shortest Latency Time First): cel ce așteaptă cel mai puțin va fi servit primul

 Altă metodă (statică) – numerotarea întrețesută a sectoarelor în cadrul unei piste:

- a) numerotare normală
- b) numerotare întrețesută cu factorul 1
- c) numerotare întrețesută cu factorul 2



- Formatarea fizică (i.e., formatarea low-level)
 - Înseamnă operația de împărțire a discului în sectoare pe care controlerul de disc le poate citi și scrie
 - Observație: vreme de cca. 3 decenii (anii '80 200x) dimensiunea sectoarelor a fost de 512 B (doar informația utilă), iar prin anii 200x au apărut discuri cu sectoare de 4096 B (discuri numite Advanced Format) și au devenit standard pentru toți producătorii începând cu 2011
 - "Tranziția" de la discurile cu sectoare de 512B la cele cu sectoare de 4KB a durat aproape un deceniu, datorită nevoii de a rescrie multe componente software ce foloseau implicit sectoare de 512B
 - Primele modele de discuri AF permiteau *emularea* sectoarelor de 512B pentru a ușura tranziția, având însă și un dezavantaj: emularea era "costisitoare" (d.p.d.v. al performanței acceselor la disc pentru operații de scriere)

Referințe: https://en.wikipedia.org/wiki/Advanced_Format

- Pentru a stoca fișiere pe disc, SO-ul trebuie să-și înregistreze propriile structuri de date pe disc
 - Partiționarea discului într-unul sau mai multe grupuri de cilindri, numite partiții, fiecare partiție putând stoca un sistem de fișiere

Notă: există mai multe scheme de partiționare a unui disc:

- MBR: standardul folosit de PC-urile mai vechi (cu firmware BIOS)
- GPT: standardul folosit de PC-urile mai noi (cu firmware UEFI) ș.a.
- Formatarea logică a unei partiții = "crearea sistemului de fișiere" rezident pe acea partiție
- Blocul de boot folosit pentru inițializarea sistemului de calcul:
 - Bootstrap-ul este păstrat în memoria ROM
 - programul bootstrap loader este păstrat pe disc în blocul de boot

- Schema de partiționare MBR
 - este standardul de partiționare folosit de PC-urile cu BIOS
 - un disc partiționat după această schemă va conține:
 - prima pistă este zonă rezervată (63 sectoare la discurile cu 512B/sector)
 - maxim 4 partiții primare, din care una poate fi partiție extinsă (i.e., poate conține un număr oarecare de partiții logice)
 - primul sector din cadrul primei piste se numește sectorul MBR (= Master Boot Record) și reprezintă blocul de boot, ce conține următoarele informații:
 - primii 446 octeți: conțin programul bootstrap loader
 - următorii 64 octeți: conțin tabela de partiții (cu informații despre poziția pe disc a celor 4 partiții primare și tipul sistemelor de fișiere stocate)
 - ultimii 2 octeți conțin întotdeauna valoarea 55AA (cu rol de semnătură)
 - restul de 62 sectoare din cadrul primei piste sunt rezervate (pentru programe de bootstrap mai mari de 446 octeți, e.g. grub 1.0 stage2)

- Alocarea blocurilor pe disc poate adresa ambele probleme, a timpului de căutare și a latenței de rotație
- Alocarea blocurilor urmărește scopuri competitoare:
 - costul alocării
 - lățimea de bandă pentru transferul unor volume mari de date
 - eficiența operațiilor cu directoare
- **Scop**: reducerea mișcării brațului (cu capetele R/W ale) discului și a *overhead*-ului datorat *seek*-urilor
 - metrica utilizată: lățimea de bandă utilizată
- Metode de gestiune a blocurilor bad (e.g. sector sparing)

- O abordare posibilă pentru alocarea blocurilor:
 - Grupurile de cilindri utilizate de FFS (Fast File System)
 - FFS definește grupurile de cilindri drept unitatea de localitate a discului și factorizează localitatea în posibilități de alegere pentru alocare
 - Strategia: plasarea blocurilor de date "înrudite" în același grup de cilindri ori de câte ori acest lucru este posibil

Despre FFS: a fost o reimplementare a sistemului de fișiere proiectat în versiunea inițială de UNIX, practic un nou sistem de fișiere, introdus în versiunea 4.2 de BSD UNIX.

Mai multe detalii puteți citi în articolul disponibil aici:

https://people.eecs.berkeley.edu/~brewer/cs262/FFS.pdf

Gestiunea spațiului de swap /1

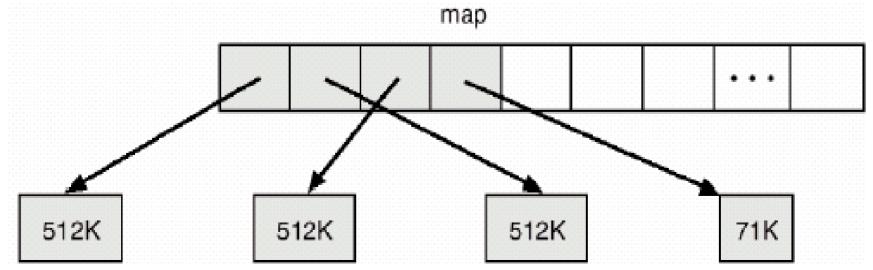
• Spațiul de swap

- Memoria virtuală utilizează spațiu pe disc drept o extensie a memoriei principale
- Spațiul de swap poate fi localizat:
 - într-un fișier (sau mai multe) din sistemul normal de fișiere (e.g. Windows)
 - pe o partiție (sau un disc) separată (e.g. UNIX/Linux)

Gestiunea spațiului de swap /2

• Exemplu:

- UNIX BSD 4.3 îi alocă spațiu de swap la începutul execuției procesului
- spațiul alocat conține:
 segmentul de text (programul) și segmentul de date



Construirea unui disc mai bun /1

• De ce?

- "Mai bun" a însemnat de obicei o densitate mai mare pentru producătorii de discuri – discurile mai mari sunt mai bune
- I/O bottleneck discrepanța de viteză cauzată de faptul că procesoarele devin mai rapide mult mai repede decât discurile
- O idee este de a folosi paralelismul mai multor discuri
 - Împrăștierea datelor (data striping) pe mai multe discuri
 - Probleme de siguranță a păstrării datelor introducerea tehnicilor de **redundanță** a datelor

• Soluție

- RAID (Redundant Array of Independent Disks)
 - Discurile multiple asigură **siguranța** păstrării datelor prin **redundanța** datelor
 - Discurile RAID se clasifică în 7 nivele RAID
 - *Striping*-ul utilizează un grup de discuri ca o singură unitate de stocare
 - Schemele RAID îmbunătățesc performanța și siguranța sistemului de stocare prin stocarea redundantă a datelor
 - prin tehnica oglindirii (*mirroring* sau *shadowing*) se păstrează un duplicat al fiecărui disc
 - tehnica block interleaved parity folosește mult mai puțină informație pentru redundanță



(a) RAID 0: non-redundant striping



(b) RAID I: mirrored disks



(c) RAID 2: memory-style error-correcting codes



(d) RAID 3: bit-interleaved Parity



(e) RAID 4: block-interleaved parity



(f) RAID 5: block-interleaved distributed parity



(g) RAID 6: P + Q redundancy

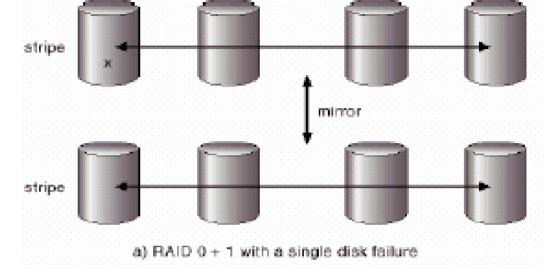
Un disc mai bun /3

Nivelele RAID

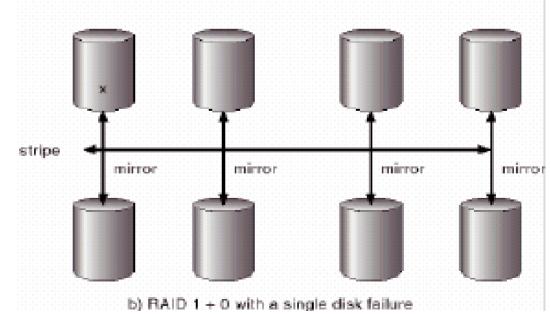
Nivelele RAID

- Nivelul 0: fără redundanță, doar striping
- Nivelul 1: discuri oglindite
- Nivelul 2: coduri Hamming corectoare de erori
- Nivelul 3: un disc de paritate la fiecare grup, bit-interleaved
- Nivelul 4: citiri/scrieri independente, block-interleaved
- Nivelul 5: datele/informația de paritate sunt împrăștiate pe toate discurile (mărește accesul concurent)
- Nivelul 6: rezistă la mai mult de o singură eroare de disc

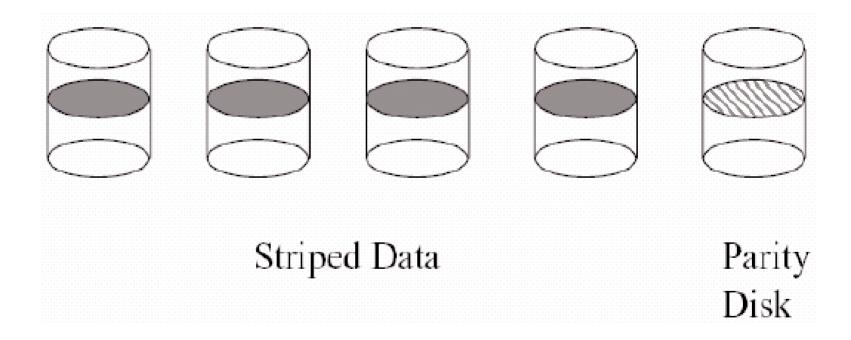
• RAID (0+1)



• RAID (1+0)



• RAID – nivelele 2 și 3



• RAID: Paritatea

- paritate bit/block-interleaved pentru toleranță la erori
- exemplu: stocarea valorii binare 1010



- Tolerează eroarea unui singur disc, întrucât eroarea este fie pe discul de paritate, fie pe unul dintre discurile de date
- Citește data, iar în caz de eroare, citește informația de paritate și corectează data eronată
- Scrierea necesită în plus și actualizarea informației de paritate

• RAID – implementare hardware:

- controlerul RAID este o placă hardware (fie discretă, fie integrată în chipsetul *northbridge*, la unele modele de plăci de bază)
- plus un set de discuri, cu caracteristici specifice nivelului RAID dorit

• RAID – implementare software:

- controlerul RAID este implementat prin software
- plus un set de discuri, cu caracteristici specifice nivelului RAID dorit

Exemple de implementări software:

- un device virtual, la nivelul nucleului SO-ului: md (Linux), softraid (OpenBSD)
- some logical volume managers: LVM (Linux), discuri dinamice create cu unealta
 Disk Management (Windows), sau tehnologia Storage Spaces (Win8/Win10)
- o componentă la nivelul *file-system-*ului: ZFS, btrfs (vezi cursul despre sisteme de fișiere)
- un nivel/o aplicație deasupra *file-system-*ului: SnapRAID, FlexRAID, etc.

Implementări la nivel de firmware+drivere specializate: e.g. Intel Matrix RAID

Referință: https://en.wikipedia.org/wiki/RAID#Implementations

Administrarea memoriei terțiare /1

- Caracteristica definitorie a memoriei terțiare: costul scăzut
- În general, memoria terțiară este construită folosind medii de stocare de tip *removable* (e.g. dischete, CD/DVD-uri, memorii flash, discuri clasice (i.e. magnetice) externe)
- Sunt disponibile și alte tipuri... (e.g. discuri SSD externe)

Administrarea memoriei terțiare /2

• Discuri removable:

- Discul floppy (discheta) un disc subțire și flexibil, acoperit cu un strat de material magnetic și închis într-o carcasă protectivă de plastic
- Discul magneto-optic înregistrează datele pe un platan rigid acoperit cu un strat de material magnetic
- Discul optic nu utilizează magnetismul; se folosesc materiale speciale ce sunt modificate de raza laser
- Medii WORM (Write Once, Read Many times)
 - Exemple: CD-uri, DVD-uri
- Benzi magnetice
- Memorii flash (diverse tehnologii de tip NAND)
 - Exemple: stick-uri USB, card-uri de memorie (în diverse formate:
 CF, SD, MMC, ş.a.), disk-uri SSD (cu diverse interfețe: SATA, NVMe, ş.a.)

Bibliografie

• Bibliografie obligatorie

capitolele despre *administrarea perifericelor* de stocare din

- Silberschatz: "Operating System Concepts" (cap.11 din [OSC10])

sau

- Tanenbaum: "Modern Operating Systems" (cap.5, §5.4 din [MOS4])

Exerciții de seminar

- Aplicații la: Planificarea acceselor la disc
 - Enunț: Se consideră un disc hard cu următoarele caracteristici: timpul de căutare este direct proporțional cu distanța parcursă de braţul cu capetele de citire/scriere, fiind de 2 ms între oricare doi cilindri consecutivi; timpul de transfer este neglijabil; iar latența de rotație este, în medie, de 1 ms pentru orice cerere de servire. La momentul t = 0 în coada de servire ajung următoarele cereri de acces la cilindrii discului: 20, 48, 85, iar la momentul t = 100 ms în coada de servire mai ajung şi următoarele cereri de acces la cilindrii discului: 33, 94, 120.

Care este ordinea satisfacerii cererilor și timpul necesar pentru satisfacerea lor, folosind algoritmul LOOK? Braţul discului este poziționat iniţial la cilindrul 50, iar sensul său de deplasare este spre cilindrul cu numărul maxim.

Reprezentați grafic ordinea de servire într-o diagramă plană x0y, pe axa orizontală fiind reprezentați cilindrii discului, iar pe cea verticală timpul.

- Rezolvare: ?

Sumar

- > Introducere
- Memoria secundară (discul)
 - Structura
 - Planificarea
 - Administrarea
- Gestiunea spațiului de swap
- > Construirea unui disc mai bun
- > Administrarea memoriei terțiare

Întrebări?